Proyecto de analisis de ventas en una tienda de ropa

Recopilación y limpieza de datos: Se recolectaron datos de una pequeña Tienda de Ropa en la ciudad de Pasto, los datos de ventas desde el mes de mayo 2022 hasta diciembre 2022, incluyendo información sobre fechas, productos, precios, etc. Estos datos se limpiarán para eliminar cualquier información faltante o incorrecta.

Análisis exploratorio de datos: Se analizarán los datos recolectados para identificar patrones y tendencias en las ventas, principalmente con ventas totales por mes y colores vendidos por mes. Se crearán gráficos y tablas para visualizar esta información.

Selección de características: Se seleccionarán las características relevantes para el modelo de machine learning, como la fecha, el precio del producto, entre otros

Entrenamiento del modelo: Se utilizará un algoritmo de aprendizaje automático para entrenar el modelo con los datos de ventas históricos y las características seleccionadas.

Evaluación del modelo: Se evaluará el rendimiento del modelo utilizando técnicas como la validación cruzada y la prueba de conjunto de prueba para medir la precisión de las predicciones.

(Implementación y monitoreo: Finalmente, se implementaría el modelo en un entorno de producción y se monitorearía su rendimiento continuamente para detectar y corregir cualquier problema.)

Carga de Datos

In [83]:
```
import pandas as pd

# Cargar el archivo csv en un DataFrame
data = pd.read_csv('Datos/VentasTiendaA.csv')

# Imprimir las primeras filas del DataFrame
data.head()
```

Out[83]:

	fecha_venta	hora_venta	Producto	Valor_sugerido	venta_final	venta_inventario	valor_compra	c
0	2022-05-31	1330.0	Gaban Negro Totas	89000.0	82000	NaN	NaN	
1	2022-05-31	1330.0	Blusa rosa Tulcan	66000.0	58000	NaN	NaN	
2	2022-06-01	1600.0	Blusa tejida caracol	59000.0	50000	NaN	NaN	
3	2022-06-02	1000.0	Gaban Murcielago	72000.0	60000	NaN	NaN	
4	2022-06-06	1400.0	Chaqueta Totas	93000.0	72500	NaN	NaN	

Consultas Exploratorias

Se utiliza el atributo shape de un DataFrame de Pandas para obtener la cantidad de filas y columnas. El primer elemento de la tupla devuelta es el número de filas y el segundo elemento es el número de columnas.

¿Cuantas filas tiene el DataFrame?

In [84]:
```
num_rows = data.shape[0]
print(num_rows)
```

```
396
```

¿Cuantos atributos tiene el DataFrame?

In [85]:
```
num_columns = data.shape[1]
print(num_columns)
```

```
16
```

¿Cuales son los nombres de los 16 atributos?

El atributo columns de un DataFrame de Pandas puede obtener una lista con los nombres de las columnas.

In [86]:
```
col_names = data.columns.tolist()
print(col_names)
```

```
['fecha_venta', 'hora_venta', 'Producto', 'Valor_sugerido', 'venta_final', 'venta_inv
entario', 'valor_compra', 'contribucion', 'Comprador', 'fecha_ingreso_inventario', 'N
OMBRE', 'sexo_producto', 'color_prenda', 'talla_prenda', 'proveedor', 'OBSERVACIONE
S']
```

¿Cual es la fecha de la primera y última venta?

Para validar el rago de fecha en que se encuentras los datos recolectados se usará min() y max() de la columna de 'fecha_venta' en el DataFrame de Pandas.

In [87]:
```
first_sale_date = data['fecha_venta'].min()
print(first_sale_date)

last_sale_date = data['fecha_venta'].max()
print(last_sale_date)
```

```
2022-05-23
2022-12-31
```

Se tuvo en cuenta que la columna fecha_venta debe ser de tipo datetime para poder utilizar min() y max().

También se puede asegurar de que tenga un formato valido utilizando previamente pd.to_datetime([ ]) así como se realizará en la siguiente sección.

¿Cuál es el valor total de las ventas realizadas por cada mes?

Se crea la columna de 'month' que contiene solo el numero del mes de la columna 'fecha_venta' y con el método groupby() del DataFrame se agrupan las ventas por mes y luego se utiliza sum() para obtener el valor total de las ventas por mes. En este caso, se devolverá una serie con un índice correspondiente al numero de cada mes y el valor siendo el total de las ventas para cada mes.

In [88]:
```
data['fecha_venta'] = pd.to_datetime(data['fecha_venta'])
data['month'] = data['fecha_venta'].dt.month
sales_by_month = data.groupby(['month'])['venta_final'].sum()
print(sales_by_month)
```

```
month
5      200000
6     2869000
7     2415000
8     1977000
9     2300000
10    1999000
11    2828000
12    7344000
Name: venta_final, dtype: int64
```

¿Cuál es el mes de mayor ventas y su valor?

Se utiliza el método idxmax() para obtener el índice del mes con la mayor venta y su valor, después de haber agrupado las ventas por mes y sumado el valor de ventas para cada mes.

In [89]:
```
max_sales_month = sales_by_month.idxmax()
print(max_sales_month)
print("Total de Ventas en el mes de mayor venta: ", sales_by_month.loc[max_sales_month
```

```
12
Total de Ventas en el mes de mayor venta:  7344000
```

¿Cuál es el mes de menor ventas y su valor?

Y se utiliza idxmin() para obtener el índice del mes con menor venta.

In [90]:
```
min_sales_month = sales_by_month.idxmin()
print(min_sales_month)
print("Total de Ventas en el mes de menor venta: ", sales_by_month.loc[min_sales_month
```

```
5
Total de Ventas en el mes de menor venta:  200000
```

¿Cual es el promedio de ventas por mes?

Con el método mean() de una serie se obtiene el promedio de las ventas de los 8 meses.

In [91]:
```
average_sales = sales_by_month.mean()
print(average_sales)
```

```
2741500.0
```

El método mean() devuelve el valor promedio de los valores disponibles en el DataFrame. Para calcular el promedio solo para los 7 meses específicos (los cuales son los más representativos para este caso), utilizamos .loc[] antes de calcular el promedio.

In [92]:
```
average_sales = sales_by_month.loc[[6, 7, 8, 9, 10, 11, 12]].mean()
print(average_sales)
```

```
3104571.4285714286
```

Redondear el valor

round() para redondear el valor promedio resultante a un número específico de decimales. El siguiente código redondeará el valor promedio a 2 decimales:

In [93]:
```
rounded_average = round(average_sales, 2)
print(rounded_average)
```

```
3104571.43
```

Gráfica #1

Comenzamos instalando e importando la librería matplotlib para graficar las ventas por cada mes y una línea transversal que indique el valor promedio desde el mes 6.

In [94]:
```
! pip install matplotlib
```

```
Requirement already satisfied: matplotlib in c:\users\principal\anaconda3\envs\diana
\lib\site-packages (3.6.3)
Requirement already satisfied: pyparsing>=2.2.1 in c:\users\principal\anaconda3\envs
\diana\lib\site-packages (from matplotlib) (3.0.4)
Requirement already satisfied: kiwisolver>=1.0.1 in c:\users\principal\anaconda3\envs
\diana\lib\site-packages (from matplotlib) (1.4.4)
Requirement already satisfied: cycler>=0.10 in c:\users\principal\anaconda3\envs\dian
a\lib\site-packages (from matplotlib) (0.11.0)
Requirement already satisfied: packaging>=20.0 in c:\users\principal\anaconda3\envs\d
iana\lib\site-packages (from matplotlib) (21.3)
Requirement already satisfied: fonttools>=4.22.0 in c:\users\principal\anaconda3\envs
\diana\lib\site-packages (from matplotlib) (4.38.0)
Requirement already satisfied: python-dateutil>=2.7 in c:\users\principal\anaconda3\e
nvs\diana\lib\site-packages (from matplotlib) (2.8.2)
Requirement already satisfied: pillow>=6.2.0 in c:\users\principal\anaconda3\envs\dia
na\lib\site-packages (from matplotlib) (9.4.0)
Requirement already satisfied: numpy>=1.19 in c:\users\principal\anaconda3\envs\diana
\lib\site-packages (from matplotlib) (1.22.3)
Requirement already satisfied: contourpy>=1.0.1 in c:\users\principal\anaconda3\envs
\diana\lib\site-packages (from matplotlib) (1.0.6)
Requirement already satisfied: six>=1.5 in c:\users\principal\anaconda3\envs\diana\li
b\site-packages (from python-dateutil>=2.7->matplotlib) (1.16.0)
```

Para graficar las ventas por cada mes, se puede utilizar el método .plot() de una serie de ventas por mes y el argumento kind='bar' el cual indica que se desea graficar un gráfico de barras.

Para agregar una línea transversal que indique el valor promedio desde el mes 6, utilizamos axhline() de la librería matplotlib.

In [95]:
```
sales_by_month.plot(kind='bar')
plt.axhline(average_sales, color='r', linestyle='--')
plt.show()
```

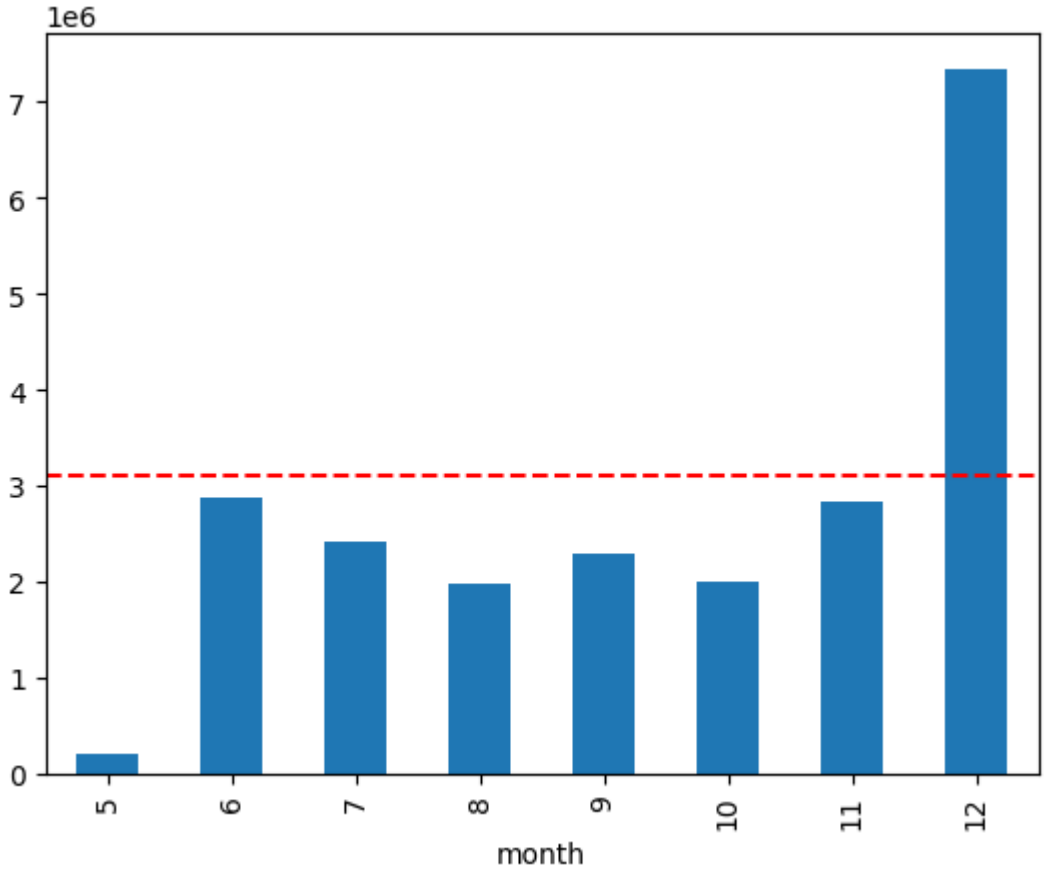

Queremos obtener una grafica más interactiva por lo cual vamos a instalar altair y codificar para obterner graficas con un poco más de detalles.

In [96]:
```
! pip install altair
```

```
Requirement already satisfied: altair in c:\users\principal\anaconda3\envs\diana\lib
\site-packages (4.2.0)
Requirement already satisfied: entrypoints in c:\users\principal\anaconda3\envs\diana
\lib\site-packages (from altair) (0.4)
Requirement already satisfied: pandas>=0.18 in c:\users\principal\anaconda3\envs\dian
a\lib\site-packages (from altair) (1.4.2)
Requirement already satisfied: toolz in c:\users\principal\anaconda3\envs\diana\lib\s
ite-packages (from altair) (0.12.0)
Requirement already satisfied: jsonschema>=3.0 in c:\users\principal\anaconda3\envs\d
iana\lib\site-packages (from altair) (4.16.0)
Requirement already satisfied: numpy in c:\users\principal\anaconda3\envs\diana\lib\s
ite-packages (from altair) (1.22.3)
Requirement already satisfied: jinja2 in c:\users\principal\anaconda3\envs\diana\lib
\site-packages (from altair) (3.1.2)
Requirement already satisfied: pyrsistent!=0.17.0,!=0.17.1,!=0.17.2,>=0.14.0 in c:\us
ers\principal\anaconda3\envs\diana\lib\site-packages (from jsonschema>=3.0->altair)
(0.18.1)
Requirement already satisfied: attrs>=17.4.0 in c:\users\principal\anaconda3\envs\dia
na\lib\site-packages (from jsonschema>=3.0->altair) (22.1.0)
Requirement already satisfied: pytz>=2020.1 in c:\users\principal\anaconda3\envs\dian
a\lib\site-packages (from pandas>=0.18->altair) (2022.1)
Requirement already satisfied: python-dateutil>=2.8.1 in c:\users\principal\anaconda3
\envs\diana\lib\site-packages (from pandas>=0.18->altair) (2.8.2)
Requirement already satisfied: MarkupSafe>=2.0 in c:\users\principal\anaconda3\envs\d
iana\lib\site-packages (from jinja2->altair) (2.1.1)
Requirement already satisfied: six>=1.5 in c:\users\principal\anaconda3\envs\diana\li
b\site-packages (from python-dateutil>=2.8.1->pandas>=0.18->altair) (1.16.0)
```

Gráfica #2

In [97]:
```
import altair as alt

chart = alt.Chart(sales_by_month.reset_index()).mark_bar().encode(x='month',y='venta_f

(chart).display()
```

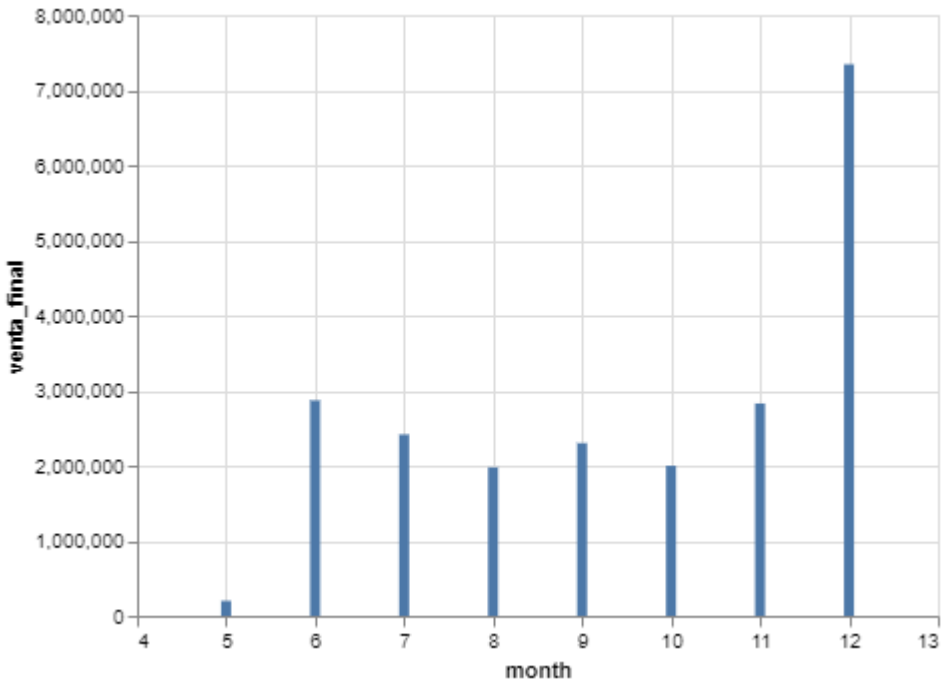

COLORES

¿Cual es la cantidad de diferentes colores vendidos por mes? Aquí también utilizamos .groupby() así como el conteo de colores unicos y los meses como indices.

In [98]:
```
# Grupos de datos por colores y conteo de colores unicos
sales_by_month = data.groupby('month')['color_prenda'].nunique().reset_index()
sales_by_month = sales_by_month.rename(columns={'color_prenda':'cantidad_colores'})
# Imprime el resultado en una tabla
print(sales_by_month)
```

```
   month  cantidad_colores
0      5                 0
1      6                 3
2      7                15
3      8                13
4      9                15
5     10                12
6     11                15
7     12                34
```

Queremos saber los diferentes colores vendidos, para la cual se toma como muestre el mes 11.

In [99]:
```
month_11_data = data.query("month == 11")
colors_month_11 = month_11_data["color_prenda"].unique()
print(colors_month_11)
```

```
['CAFE' 'NEGRO' 'VERDE' 'NARANJA' 'GRIS CLARO' 'ROSADO' 'MOSTAZA' 'CRUDO'
 'GRIS' 'ROJO' 'CAMEL' 'AZUL' 'NEGRO BLANCO' 'NEGRO-BEIGE' 'CREMA']
```

También quermos que esta lista este en orden Descendente según la candidad de prendas vendidas por color, para esto utilizamos .sort_values(" ",ascending=False) y .reset_index(drop=True)

In [100…
```
month_11_data = data[data["month"] == 11]
color_month_11 = month_11_data.groupby("color_prenda").size().reset_index(name="cantic
color_month_11 = color_month_11.sort_values("cantidad_colores",ascending=False)
color_month_11 = color_month_11.reset_index(drop=True)
colors_month_11 = color_month_11["color_prenda"].tolist()
print(colors_month_11)
```

```
['NEGRO', 'GRIS', 'ROJO', 'AZUL', 'CAMEL', 'CRUDO', 'GRIS CLARO', 'MOSTAZA', 'VERDE',
'CAFE', 'CREMA', 'NARANJA', 'NEGRO BLANCO', 'NEGRO-BEIGE', 'ROSADO']
```

Probamos que estos datos se puedan mostrar como una tabla

In [101…
```
month_11_data = data.query("month == 11")
colors_month_11 = month_11_data.groupby(["color_prenda"]).size().reset_index(name="car
colors_month_11 = colors_month_11.sort_values("cantidad_prendas",ascending=False)
colors_month_11 = colors_month_11.reset_index(drop=True)
print(colors_month_11)
```

	color_prenda	cantidad_prendas
0	NEGRO	17
1	GRIS	7
2	ROJO	5
3	AZUL	3
4	CAMEL	2
5	CRUDO	2
6	GRIS CLARO	2
7	MOSTAZA	2
8	VERDE	2
9	CAFE	1
10	CREMA	1
11	NARANJA	1
12	NEGRO BLANCO	1
13	NEGRO-BEIGE	1
14	ROSADO	1

¿Cuales son los colores más vendidos en los últimos 7 meses de 2022?

Para esto utilizamos '.query' con un rango de fechas.

In [102…

```
month_6_12_data = data.query("month >= 6 & month <= 12")
colors_month_6_12 = month_6_12_data.groupby(["color_prenda"]).size().reset_index(name=
colors_month_6_12 = colors_month_6_12.sort_values("cantidad_prendas",ascending=False)
colors_month_6_12 = colors_month_6_12.reset_index(drop=True)
print(colors_month_6_12)
```

	color_prenda	cantidad_prendas
0	NEGRO	96
1	GRIS	59
2	AZUL	28
3	ROSADO	24
4	ROJO	19
5	GRIS CLARO	13
6	BLANCO	13
7	VERDE	11
8	BEIGE	7
9	CAFE	7
10	CRUDO	7
11	MOSTAZA	5
12	CREMA	5
13	CAMEL	4
14	GRIS OSCURO	4
15	MORADO	4
16	TERRACOTA	3
17	AGUA MARINA	3
18	NARANJA	3
19	VINOTINTO	3
20	GRIS MEDIO	3
21	AZUL OSCURO	3
22	NEGRO BLANCO	2
23	ROSA GUAVA	1
24	VINO TINTO	1
25	VERDE OSCURO	1
26	VERDE CLARO	1
27	TOMATE	1
28	BEIS	1
29	TABACO	1
30	BLANCO NEGRO	1
31	MENTA	1
32	ROSA	1
33	GRIS NEGRO	1
34	PIEL	1
35	PERLA	1
36	PALO ROSA	1
37	NEGRO-GRIS	1
38	NEGRO-BLANCO	1
39	NEGRO-BEIGE	1
40	AMARILLO	1
41	CIAN	1

Gráfica #3

Queremos ver la anterior tabla, para lo cual utilizamos matplotlip

In [103…

```
# Datos para graficar
x = colors_month_6_12['color_prenda']
y = colors_month_6_12['cantidad_prendas']

fig, ax = plt.subplots()
ax.plot(x, y)

ax.set(xlabel='Colores', ylabel='Cantidad de prendas vendidas',
       title='Ventas de prendas por color desde el mes 6 al 12')
ax.grid()
```

```
plt.xticks(rotation = 90)
plt.tight_layout()
plt.show()
```